

MACHINE LEARNING · EVALUACIÓN DE MODELOS

Matriz de Confusión

Cómo medir, interpretar y comparar el rendimiento de modelos de clasificación.



Clase

Al finalizar, serás capaz de...

- 1 Comprender por qué es necesario evaluar modelos de clasificación.
- 2 Comparar distintos algoritmos de Machine Learning.
- 3 Entender la estructura de una matriz de confusión.
- 4 Interpretar correctamente sus filas y columnas.
- 5 Identificar TP, TN, FP y FN.
- 6 Diferenciar aciertos y errores de clasificación.
- 7 Usar la matriz para comparar modelos.
- 8 Manejar matrices binarias y multiclase.
- 9 Verla como base de métricas más avanzadas.

PARTE 1

¿Por qué evaluar modelos?

Del problema de clasificación a la necesidad de medir el rendimiento.

Muchos algoritmos, un mismo objetivo

En Machine Learning existen muchos algoritmos distintos para resolver problemas de **clasificación**. Todos pueden usarse para hacer predicciones.

La pregunta central de esta clase

¿Cómo sabemos cuál funciona mejor?

Algoritmos de clasificación

KNN

K Nearest Neighbors

Árboles

Árboles de decisión

Random Forest

Conjunto de árboles

Reg. Logística

Regresión Logística

SVM

Support Vector Machines

Gradient Boosting

Modelos secuenciales

Todos usan los mismos datos, pero no obtienen los mismos resultados.

Predecir enfermedad cardíaca

Con datos clínicos de cada paciente queremos predecir una de dos clases posibles.

Datos disponibles

- Dolor de pecho
- Circulación sanguínea
- Arterias bloqueadas
- Peso
- Otros indicadores clínicos

Queremos predecir

Tiene enfermedad cardíaca

No tiene enfermedad cardíaca

Tenemos varios algoritmos

Podemos entrenar distintos modelos sobre exactamente los mismos datos.

KNN

Mismos datos de entrada

Random Forest

Mismos datos de entrada

Regresión Logística

Mismos datos de entrada

Pero no necesariamente obtienen los mismos resultados. Por eso necesitamos compararlos.

¿Cómo comparamos modelos?


No basta con una impresión

“Este algoritmo parece bueno” no es una medida.

Necesitamos una medida objetiva


Evaluamos el rendimiento usando datos que el algoritmo **nunca vio durante el entrenamiento**. Así sabemos si realmente generaliza.

Training Data y Testing Data



Entrenando los modelos

Cada algoritmo aprende usando el conjunto de entrenamiento.



Probando los modelos

Ahora usamos los datos de prueba.

El modelo debe hacer predicciones sobre pacientes que **nunca vio antes**.

Cada predicción se compara con la realidad para saber si acertó o falló.

Cuatro pacientes de prueba

Paciente 1

Correcto

Realidad: Tiene enfermedad

Predicción: Tiene enfermedad

Paciente 2

Incorrecto

Realidad: Tiene enfermedad

Predicción: No tiene enfermedad

Paciente 3

Incorrecto

Realidad: No tiene enfermedad

Predicción: Tiene enfermedad

Paciente 4

Correcto

Realidad: No tiene enfermedad

Predicción: No tiene enfermedad

Necesitamos resumir los resultados

Con cientos o miles de pacientes necesitamos responder rápidamente:

?

¿Cuántos casos acertó?

?

¿Cuántos casos falló?

?

¿Qué tipo de errores
cometió?

La herramienta que responde todo esto: **la Matriz de Confusión**

PARTE 2

La Matriz de Confusión

Estructura, cuadrantes y los cuatro tipos de resultado.

DEFINICIÓN

¿Qué es la matriz de confusión?

Una tabla que resume el desempeño de un clasificador comparando **lo que predijo** con **lo que realmente ocurrió**.

Filas

Representan lo que PREDIJO el algoritmo.

Columnas

Representan la REALIDAD (lo que era verdad).

Filas = predicción · Columnas = realidad

		REAL	
		Sí	No
PREDICE	Sí	?	?
	No	?	?

Cada celda cuenta los casos que caen en esa combinación de predicción y realidad.

CUADRANTE 1

True Positive (TP)

		REAL	
		Sí	No
PREDICE Sí	TP	?	
PREDICE No	?	?	

TP

Pacientes que tenían la enfermedad y fueron correctamente identificados como enfermos.

CUADRANTE 2

True Negative (TN)

	REAL	
	Sí	No
PREDICE Sí	?	?
PREDICE No	?	TN

TN

Pacientes que no tenían la enfermedad y fueron correctamente identificados como sanos.

CUADRANTE 3

False Negative (FN)

		REAL	
		Sí	No
PREDICE Sí		?	?
PREDICE No		FN	?

FN

Pacientes que tenían la enfermedad pero fueron clasificados, por error, como sanos.

CUADRANTE 4

False Positive (FP)

		REAL	
		Sí	No
PREDICE Sí	?		FP
PREDICE No	?		?

FP

Pacientes sanos que fueron clasificados, por error, como enfermos.

La matriz completa

		REAL			
		Sí	No		
PREDICE	Sí	TP	FP	TP	Verdadero positivo
	No <td>FN</td> <td>TN</td> <td>TN</td> <td>Verdadero negativo</td>	FN	TN	TN	Verdadero negativo
				FP	Falso positivo
				FN	Falso negativo



Acierto (diagonal)



Error (fuera de la diagonal)

PARTE 3

Interpretación y comparación

De los números concretos a la decisión sobre qué modelo usar.

Resultados de un modelo

		REAL	
		Enfermo	Sano
PREDICE	Enfermo	142	22
	Sano	29	110

 Acierto (diagonal)  Error (fuera de la diagonal)

¿Qué significa cada número?

142

Enfermos correctamente
identificados

110

Sanos correctamente
identificados

29

Enfermos clasificados
como sanos

22

Sanos clasificados como
enfermos

La diagonal principal

		REAL	
		Enfermo	Sano
PREDICE Enf.	142	22	
PREDICE Sano	29	110	

Diagonal principal

142 y 110 son los aciertos del algoritmo.

Fuera de la diagonal

22 y 29 son los fallos del algoritmo.

Regla fundamental



Diagonal

= Clasificación CORRECTA



Fuera de la diagonal

= ERROR de clasificación

Random Forest vs. K Nearest Neighbors

Random Forest

REAL

	Enf.	Sano
Pred. Enf.	142	22
Pred. Sano	29	110

K Nearest Neighbors

REAL

	Enf.	Sano
Pred. Enf.	107	45
Pred. Sano	64	79



Acierto (diagonal)



Error (fuera de la diagonal)

SUMANDO LA DIAGONAL

¿Cuál parece mejor?

Random Forest

142 + 110

252

aciertos

K Nearest Neighbors

107 + 79

186

aciertos

Random Forest acertó más casos → parece la mejor alternativa para este problema.

¿Y si dos modelos son muy parecidos?

A veces dos algoritmos producen matrices **muy similares** — por ejemplo, Random Forest y Regresión Logística.

En ese caso...

Resulta difícil decidir cuál es mejor observando ***solamente*** la matriz de confusión.

Necesitaremos métricas derivadas para desempatar.

Métricas derivadas de la matriz

La matriz de confusión es muy útil, pero no siempre es suficiente. De ella nacen métricas más precisas:



Precision



Recall



Sensitivity



Specificity



F1 Score



ROC Curve



ROC AUC

Las estudiaremos en detalle más adelante.

PARTE 4

Más allá de lo binario

Matrices multiclase: la misma idea para cualquier número de categorías.

Matrices multiclase

Hasta ahora trabajamos con solo dos resultados posibles: **Enfermo** o **Sano**.

Esto produce una matriz

$$2 \times 2$$

Pero muchos problemas tienen más de dos categorías.

Predecir la película favorita

Ahora hay tres opciones posibles en lugar de dos.

Película A

Película B

Película C

Con 3 categorías, la matriz ya no es 2×2 : será 3×3

Estructura 3 × 3

		REAL		
		A	B	C
PREDICE A		?	?	?
PREDICE B		?	?	?
PREDICE C		?	?	?



Acierto (diagonal)



Error (fuera de la diagonal)

LA REGLA NO CAMBIA

Diagonal = aciertos, resto = errores

		REAL		
		A	B	C
PREDICE A		✓	✗	✗
PREDICE B		✗	✓	✗
PREDICE C		✗	✗	✓

$A \rightarrow A$, $B \rightarrow B$ y $C \rightarrow C$ son aciertos. Todo lo demás ($A \rightarrow B$, $B \rightarrow C$, ...) son errores.

Generalización

El número de categorías define el tamaño de la matriz.

2 × 2

2 clases

3 × 3

3 clases

4 × 4

4 clases

10 × 10

10 clases

40 × 40

40 clases

Más categorías → matriz más grande, misma lógica de diagonal.

FÓRMULA GENERAL

N categorías → **matriz $N \times N$**

Si el problema tiene

N

categorías

La matriz tendrá

$N \times N$

N filas y N columnas

Idea fundamental

La matriz de confusión no está limitada a problemas binarios.

Puede utilizarse para cualquier problema de clasificación, con el número de clases que sea.

Resumen final

Filas

Lo que predice el modelo

Columnas

La realidad

Diagonal

Clasificaciones correctas

Fuera de la diagonal

Clasificaciones incorrectas

Tamaños

2×2, 3×3, 4×4 ... N×N

Base para

Precision, Recall, F1, ROC AUC...

MENSAJE DE CIERRE

La matriz de confusión muestra exactamente dónde acierta y dónde se equivoca un modelo.

Es el punto de partida para entender si un clasificador realmente funciona.

Gracias.