


PRESENTACIÓN CONCEPTUAL • INTRODUCCIÓN

Introducción a los problemas de Machine Learning

Cómo pasar de los datos a las predicciones, agrupamientos y decisiones

Una mirada simple y visual a qué es el aprendizaje automático y qué tipos de problemas resuelve.



Un recorrido de lo general a lo concreto

01

Qué es Machine Learning

La idea de aprender desde datos

02

Programación tradicional vs ML

Reglas escritas vs patrones aprendidos

03

Definir bien el problema

Datos de entrada, variable objetivo y salida

04

Aprendizaje supervisado

Clasificación y regresión

05

Aprendizaje no supervisado

Clustering, anomalías y reducción

06

Elegir y llevar a producción


Guía de decisión y metodología general

CONCEPTO

¿Qué es Machine Learning?

Machine Learning (aprendizaje automático) es una forma de construir sistemas que **aprenden patrones a partir de datos**, en lugar de seguir reglas escritas una por una.

- **Aprende de la experiencia.** Usa ejemplos pasados para mejorar sin ser reprogramado.
- **Generaliza a casos nuevos.** Aplica lo aprendido a datos que nunca vio antes.
- **Se adapta a los datos.** El mismo método sirve para problemas muy distintos.



LA IDEA CENTRAL

“En lugar de programar todas las reglas manualmente, usamos **datos históricos para que un **modelo aprenda patrones** y los aplique a casos **nuevos.**”**

Este cambio de enfoque es lo que hace tan potente y flexible al aprendizaje automático.

El aprendizaje automático ya está en todas partes

72%

de las organizaciones ya usan IA
en al menos una función de
negocio

33% → 65%

salto de la IA generativa en un
solo año: adopción sin
precedentes

83%

de las empresas la consideran una
prioridad estratégica

3,5×

retorno promedio reportado por
los primeros adoptantes

Fuentes: McKinsey Global AI Survey · IBM Institute for Business Value · Salesforce State of AI.

Programación tradicional vs Machine Learning

Programación tradicional

Reglas + Datos = Resultado

- El experto escribe manualmente las reglas.
- Los datos entran y se aplican esas reglas.
- Si el problema cambia, hay que reescribir reglas.

Machine Learning

Datos + Resultados históricos → Modelo

Modelo + Nuevos datos → Predicción

- El modelo descubre las reglas a partir de ejemplos.
- Aprende de datos y respuestas ya conocidas.
- Se adapta a casos nuevos sin reprogramar.

Detectar spam: reglas escritas vs patrones aprendidos

?

Con reglas manuales

- Si el asunto contiene “gratis” → spam
- Si hay muchos signos “!!!” → spam
- Si el remitente es desconocido → sospechoso
- *...y así cientos de reglas frágiles que hay que mantener a mano.*

✓

Con Machine Learning

- Le mostramos miles de correos etiquetados como spam o no spam.
- El modelo aprende qué combinaciones de palabras y señales predicen spam.
- Clasifica correos nuevos automáticamente.
- *Mejora al recibir más ejemplos, sin reescribir reglas.*

¿Qué tipo de preguntas puede responder?

¿Qué clase es?

Clasificación

¿Cuánto vale?

Regresión

¿Qué se parece entre sí?

Clustering

¿Qué casos son raros?

Anomalías

¿Qué variables explican mejor?

Relaciones

¿Qué puede pasar después?

Predicción

Ejemplos del mundo real

1

Detectar spam

Filtrar correo no deseado automáticamente

2

Predecir precios

Estimar el valor de una vivienda

3

Segmentar clientes

Agrupar según comportamiento de compra

4

Detectar fraude

Señalar transacciones sospechosas

5

Anticipar fallos

Prever averías de máquinas antes de que ocurran

6

Recomendar productos

Sugerir lo más relevante para cada persona

Machine Learning en distintas industrias

Salud

Apoyo al diagnóstico por imagen y predicción de riesgo del paciente

-30% hallazgos omitidos

Finanzas

Detección de fraude y scoring de crédito en tiempo real

Menos pérdidas por fraude

Retail

Pronóstico de demanda y recomendación personalizada

Mejor stock y ventas

Industria

Mantenimiento predictivo y control de calidad

Menos paradas no planificadas

Ejemplos ilustrativos basados en casos publicados por McKinsey, Databricks y reportes de industria 2025–2026.

Antes de los algoritmos: definir bien el problema

La primera pregunta no es “¿qué modelo uso?”, sino “¿qué queremos resolver?”. Un problema bien definido es la mitad de la solución.

1 ¿Qué decisión queremos mejorar?

2 ¿Qué dato queremos predecir o descubrir?

3 ¿Tenemos ejemplos históricos disponibles?

4 ¿Existe una variable objetivo (una respuesta conocida)?


5 **¿La salida esperada es una categoría, un número, un grupo o una anomalía?**

Entradas, variable objetivo, modelo y predicción



Cuando existe variable objetivo, el problema es supervisado. Cuando no existe, es no supervisado.

Predecir el precio de una casa



Dos grandes familias de problemas

Aprendizaje supervisado

Hay variable objetivo: aprendemos de ejemplos con respuestas conocidas.

Clasificación

predecir una categoría

Regresión

predecir un número

Aprendizaje no supervisado

No hay variable objetivo: buscamos estructura oculta en los datos.

Clustering

descubrir grupos

Anomalías

detectar casos raros

Reducción de dimensionalidad

simplificar variables


FAMILIA 1

Aprendizaje supervisado

Se usa cuando tenemos ejemplos históricos con respuestas conocidas. El modelo aprende de pares:

Datos de entrada → **Respuesta correcta**

Los dos grandes problemas: clasificación y regresión.



Clasificación: predecir una categoría

“¿A qué clase pertenece este caso?”

Salida típica: una categoría / etiqueta.

- ¿Este email es spam o no spam?
- ¿Esta transacción es fraude o no?
- ¿Este cliente se va o se queda?
- ¿Riesgo bajo, medio o alto?
- ¿La imagen es un gato, perro o auto?

Ejemplo visual

Spam

correo no deseado

No spam

correo legítimo

Algoritmos de referencia

`LogisticRegression` · `DecisionTreeClassifier` ·
`RandomForestClassifier`

Regresión: predecir un valor numérico

“¿Cuánto vale? ¿Cuánto será? ¿Cuánto tarda?”

Salida típica: un número continuo.

- Predecir el precio de una casa
- Estimar las ventas del próximo mes
- Predecir la temperatura
- Estimar la demanda de productos
- Calcular el tiempo de entrega

Ojo con esta confusión

Predecir el precio de una casa es **regresión**, no clasificación: la salida es **un número**, no una etiqueta.

Algoritmos de referencia

`LinearRegression` · `DecisionTreeRegressor` ·
`RandomForestRegressor`

Clasificación vs Regresión

Clasificación

Predice	categorías
Responde	¿qué clase es?
Ejemplo	spam / no spam
Salida	una etiqueta

Regresión

Predice	números
Responde	¿cuánto vale?
Ejemplo	precio de una casa
Salida	un valor numérico

Misma casa, dos preguntas:

“Económica / Media / Cara”
clasificación

“USD 185.000”
regresión


FAMILIA 2

Aprendizaje no supervisado

Se usa cuando no hay una respuesta correcta previamente marcada: no existe variable objetivo.

El objetivo es descubrir estructura, grupos, patrones o comportamientos raros dentro de los datos.

- Agrupar clientes por comportamiento
- Encontrar productos parecidos
- Detectar datos atípicos y visualizar datos complejos




Clustering: descubrir grupos

“¿Qué grupos existen en los datos?”

Salida: grupos descubiertos por el modelo (sin etiquetas previas).

- Segmentación de clientes
- Usuarios según hábitos de compra
- Agrupamiento de productos similares
- Perfiles de estudiantes por comportamiento
- Zonas geográficas por consumo



Algoritmos de referencia


KMeans · DBSCAN · AgglomerativeClustering

Detección de anomalías: casos raros

“¿Qué casos no se comportan como la mayoría?”

Salida: normal / anómalo, o un puntaje de rareza.

- Fraude con tarjeta de crédito
- Accesos sospechosos a una cuenta
- Sensores industriales con valores anormales
- Operaciones financieras fuera de patrón
- Errores en datos o comportamiento extraño en una red



Algoritmos de referencia

IsolationForest · LocalOutlierFactor · OneClassSVM


Reducción de dimensionalidad

A veces tenemos muchas variables. La reducción de dimensionalidad ayuda a simplificar, visualizar o resumir la información sin perder lo esencial.

“¿Cómo represento datos complejos de forma más simple?”

- Visualizar clientes con muchas variables en un gráfico 2D
- Reducir ruido en los datos
- Comprimir información
- Preparar datos para otros modelos

De muchas variables a pocas dimensiones



Algoritmos de referencia: PCA • t-SNE

Tabla resumen de los tipos de problemas

Tipo de problema	Pregunta que responde	Salida	Ejemplo	Algoritmos de referencia
Clasificación	¿Qué clase es?	Categoría	Spam / No spam	LogisticRegression, RandomForestClassifier
Regresión	¿Cuánto vale?	Número continuo	Precio de una casa	LinearRegression, DecisionTreeRegressor
Clustering	¿Qué grupos existen?	Grupo descubierto	Segmentos de clientes	KMeans, DBSCAN
Anomalías	¿Qué casos son raros?	Normal / Anómalo	Fraude o acceso sospechoso	IsolationForest, LocalOutlierFactor
Reducción dimensional	¿Cómo simplifico variables?	Nueva representación	Visualización de datos	PCA, t-SNE

Esta tabla es el mapa mental de toda la presentación: la forma de la salida decide el tipo de problema.

Cómo elegir el tipo de problema



Metodología general de un proyecto de ML



La limpieza y preparación de datos —un paso crítico— se verá en detalle en una presentación separada.

Un ciclo probado: CRISP-DM

La industria suele organizar estos proyectos con CRISP-DM, un ciclo de seis fases usado desde hace décadas y todavía vigente.

1. Comprensión del negocio

Qué decisión queremos mejorar

2. Comprensión de los datos

Qué datos tenemos y qué contienen

3. Preparación de los datos

Limpiar y transformar la información

4. Modelado

Entrenar el tipo de modelo elegido

5. Evaluación

Verificar si resuelve el problema real

6. Despliegue

Poner el modelo a trabajar y monitorearlo

Fuente: CRISP-DM (Cross-Industry Standard Process for Data Mining).

Ejemplos integradores del mundo real

Predecir si un cliente abandona un servicio



Clasificación

Predecir el precio de una vivienda



Regresión

Agrupar clientes por comportamiento de compra



Clustering

Detectar transacciones sospechosas



Anomalías

Visualizar clientes con muchas variables



Reducción dim.

Predecir la demanda de productos



Regresión

Detectar emails maliciosos



Clasificación

Errores comunes al empezar



Empezar por el algoritmo

Primero se define el problema y la salida; el modelo viene después.



Confundir el tipo de salida

Un número es regresión, no clasificación. La salida decide el problema.



Ignorar la calidad de los datos

Sin datos representativos, ningún modelo funciona bien.




Buscar el modelo “perfecto”

Mejor un modelo simple que funcione que uno complejo que nadie entiende.

IDEA CLAVE

El algoritmo viene después. Primero hay que entender el problema.

- Machine Learning no empieza eligiendo un modelo.
- Empieza definiendo qué queremos descubrir o predecir.
- La forma de la salida determina el tipo de problema.
- Cada tipo de problema tiene técnicas y métricas diferentes.



Lo que nos llevamos



ML aprende patrones desde datos



Supervisado: usa ejemplos con respuestas conocidas



No supervisado: descubre estructura sin respuestas



Clasificación predice categorías



Regresión predice números



Clustering descubre grupos



Anomalías detecta comportamientos raros



Reducción dimensional simplifica datos complejos

Luego podremos profundizar cada tema por separado.

CONTINUARÁ

Próximas presentaciones de la serie

Próximamente Clasificación

Métricas, umbrales y modelos en detalle

Próximamente Regresión

Cómo se evalúan las predicciones numéricas

Próximamente Detección de anomalías

Técnicas y casos de fraude y monitoreo

Próximamente Limpieza y preparación de datos

El paso que hace posible todo lo demás

¡Gracias!

De los datos a las predicciones, agrupamientos y decisiones.

Preguntas y conversación

