




GUÍA PRÁCTICA · MACHINE LEARNING

Cómo se trabaja realmente en Machine Learning

Del problema de negocio al modelo en producción

Negocio



Datos



Modelo



Decisión



Valor

ML no empieza con un algoritmo



Machine Learning no empieza con un algoritmo.

Empieza con una **decisión de negocio** que se quiere mejorar.

Preguntas que resuelve el negocio

- ¿Qué clientes pueden abandonar el servicio?
- ¿Cuánto venderemos el próximo mes?
- ¿Qué transacciones parecen fraudulentas?
- ¿Qué producto recomendar a cada cliente?
- ¿Qué precio estimado tiene una propiedad?

CASOS DE USO


¿Para qué usan ML las empresas?

Área	Uso de ML	Valor generado
Ventas	Predicción de demanda	Mejor planificación
Marketing	Segmentación de clientes	Campañas más efectivas
Banca	Detección de fraude	Menos pérdidas
Retail	Recomendaciones	Más ventas
Industria	Mantenimiento predictivo	Menos paradas
Logística	Optimización de rutas	Menores costes
RR. HH.	Análisis de rotación	Mejor retención

Clave *Una empresa no compra modelos; compra mejores decisiones.*

EL ORIGEN

Cómo nace un proyecto de Machine Learning



TRADUCCIÓN

Del problema de negocio al problema de ML

Problema de negocio	Pregunta	Tipo de problema ML
¿El cliente se irá?	Sí / No	Clasificación
¿Cuánto venderemos?	Número futuro	Regresión
¿Qué clientes son parecidos?	Grupos	Clustering
¿Esta operación es extraña?	Comportamiento raro	Detección de anomalías
¿Qué producto recomendar?	Preferencia probable	Sistemas de recomendación

Clave *El equipo de datos traduce preguntas de negocio en problemas que un modelo puede aprender.*

PROCESO

El ciclo de vida de un proyecto ML



- 1 Definir la tarea
- 2 Recolectar y preparar datos
- 3 Explorar los datos
- 4 Entrenar modelos
- 5 Validar resultados
- 6 Desplegar el modelo
- 7 Monitorizar y mejorar

Iterativo: *el modelo se revisa cuando cambian los datos o el negocio.*

EL EQUIPO

Cómo trabaja un Data Scientist



- 1 Entender el problema con usuarios de negocio
- 2 Conseguir y limpiar los datos
- 3 Explorar patrones
- 4 Crear variables relevantes
- 5 Probar algoritmos
- 6 Evaluar métricas
- 7 Comunicar resultados
- 8 Llevar el modelo a producción con ingeniería
- 9 Evaluar los resultados del modelo en producción

HERRAMIENTAS

Entornos de trabajo en Machine Learning

Aprendizaje y exploración

- Jupyter Notebook
- JupyterLab
- Google Colab
- Kaggle Notebooks

Desarrollo profesional

- VS Code + Jupyter
- PyCharm
- GitHub

Plataformas empresariales

- Azure Machine Learning
- Databricks

Gestión de entornos

- Anaconda
- Conda
- Entornos virtuales de Python

Clave Cada entorno sirve para algo distinto: aprender, experimentar u operar modelos empresariales.

Del notebook a producción

Notebook

- Exploración
- Pruebas rápidas
- Métricas iniciales
- Código experimental



Producción

- Integración con sistemas reales
- APIs · Seguridad
- Monitorización · Escalabilidad
- Retraining · Gobierno de datos

Clave *Que un modelo funcione en un notebook no significa que esté listo para una empresa.*

LA REALIDAD

Muchos modelos no llegan a producción

100 ideas

30 pruebas de concepto

10 modelos prometedores

3 despliegues

1 solución
con valor real

Diversas fuentes de la industria señalan que una parte muy alta de las iniciativas de IA/ML **no llega a producción o no genera valor medible**. Las cifras varían, pero suelen citarse rangos aproximados entre el **70% y el 90%**.

No es una ley exacta, sino una señal de un problema real: pasar de un experimento a una solución usada por la empresa es difícil.

Contexto Gartner: solo ~54% de los modelos pasa de piloto a producción · RAND (2024): fallan 80%+ de los proyectos de IA.

CAUSAS

¿Por qué fracasan tantos proyectos?

1

Problema de
negocio mal
definido

2

Datos incompletos,
inconsistentes o no
disponibles

3

Modelo
desconectado de los
sistemas reales

4

Falta de adopción
por parte de los
usuarios

5

No se demuestra
retorno de inversión

Clave *El problema rara vez es el algoritmo: suele estar en los datos, la integración, la adopción o el valor.*

CÓMO MEDIR

Métricas técnicas vs métricas de negocio

Métricas técnicas

- Accuracy
- Precision
- Recall
- F1 Score
- ROC AUC
- Error absoluto medio
- RMSE

vs

Métricas de negocio

- Ahorro generado
- Ventas incrementadas
- Fraudes evitados
- Tiempo reducido
- Clientes retenidos
- Costes disminuidos
- Decisiones automatizadas

Clave *Un modelo puede tener buenas métricas técnicas y aun así no generar valor.*

EL EQUIPO MULTIDISCIPLINARIO

Roles involucrados

Sponsor de negocio

Define el objetivo

Experto de negocio

Aporta contexto

Data Analyst

Explora y entiende datos

Data Scientist

Entrena y evalúa modelos

Data Engineer

Prepara pipelines de datos

ML Engineer

Lleva modelos a producción

DevOps / MLOps

Automatiza y monitoriza


Usuarios finales

Usan las predicciones

Un flujo común: *del objetivo de negocio a las decisiones que usan los usuarios finales.*

OPERACIÓN

MLOps: mantener vivo el modelo



Clave *El modelo no termina al entrenarse: es útil cuando se mantiene funcionando en el mundo real.*

CIERRE

El Machine Learning no es el modelo

*El valor aparece cuando el modelo **mejora una decisión**, se **integra en un proceso** y es **usado por la organización**.*



IDEA PARA RECORDAR

“

Una empresa no compra modelos.

Compra decisiones **mejores**, más **rápidas** y más **rentables**.