




GUÍA PRÁCTICA · MACHINE LEARNING

# Machine Learning en la practica

*Del problema de negocio al modelo en producción*

Negocio



Datos



Modelo



Decisión



Valor

# Con ChatGPT, la IA pasó al centro del negocio

“

**ChatGPT fue la app más rápida en llegar a 100 millones de usuarios.** En pocos meses, las empresas empezaron a mirar **el poder real de la IA** y su valor para el negocio.

## Qué cambió desde 2022

- La IA llegó a la agenda de dirección
- Más inversión y más proyectos de ML
- Casos de uso reales en cada área
- Herramientas de IA al alcance de todos
- Adopción empresarial en máximos históricos

## EL AUGE EN CIFRAS

# El crecimiento de la IA desde 2022

**100 M**

usuarios de ChatGPT en 2 meses, un récord histórico

**400 M**

usuarios semanales de ChatGPT a inicios de 2025

**78 %**

de las organizaciones ya usan IA (2024)

**×8,5**

más inversión en IA generativa que en 2022

**\$252 B**

miles de millones de inversión corporativa en IA (2024)

**×11**

más modelos de IA en producción en un año

**~50 %**

del capital de riesgo mundial se destinó a IA (2025)

**+76 %**

crecimiento del gasto mundial en IA generativa (2025)

**El dato clave:** *el interés por la IA se tradujo en inversión, adopción y modelos en producción a una escala sin precedentes.*

# ChatGPT puso el foco en el Machine Learning

“

**Debajo del fenómeno estaba el Machine Learning.**

Las empresas empezaron a ver el potencial de una **disciplina con décadas de desarrollo** y le dieron un lugar central.

Por qué ahora

- ChatGPT encendió la curiosidad empresarial
- Debajo del producto había Machine Learning
- Una disciplina con décadas de desarrollo
- Las empresas vieron su potencial de negocio
- El ML ganó foco, estudio e inversión

# ¿Auge real o solo hype?

## La expectativa

- La IA lo resuelve casi todo
- Resultados inmediatos y sin esfuerzo
- Reemplaza equipos completos
- Todo proyecto genera valor seguro



## La realidad

- 95 % de iniciativas de IA gen. no cumplen (MIT)
- 80 % de proyectos de IA fallan (RAND)
- Solo ~48 % de pilotos llegan a producción
- Del entusiasmo al valor hay un largo camino

**Clave** *El auge es real, pero pasar del entusiasmo al valor sigue siendo el gran reto.*

## LA REALIDAD

# Muchos modelos no llegan a producción

100 ideas

30 pruebas de concepto

10 modelos prometedores

3 despliegues

1 solución  
con valor real

Diversas fuentes de la industria señalan que una parte muy alta de las iniciativas de IA/ML **no llega a producción o no genera valor medible**. Las cifras varían, pero suelen citarse rangos aproximados entre el **70% y el 95%**.

*No es una ley exacta, sino una señal de un problema real: pasar de un experimento a una solución usada por la empresa es difícil.*

**Contexto** MIT (2025): ~95% de las iniciativas de IA generativa no dan retorno · RAND: fallan más del 80% de los proyectos de IA · Gartner: solo ~48% de los pilotos llegan a producción.

## CAUSAS

# ¿Por qué fracasan tantos proyectos?

1

Problema de  
negocio mal  
definido

2

Datos incompletos,  
inconsistentes o no  
disponibles

3

Modelo  
desconectado de los  
sistemas reales

4

Falta de adopción  
por parte de los  
usuarios

5

No se demuestra  
retorno de inversión

**Clave** *El problema rara vez es el algoritmo: suele estar en los datos, la integración, la adopción o el valor.*

# ML no empieza con un algoritmo



**Machine Learning no empieza con un algoritmo.**

Empieza con una **decisión de negocio** que se quiere mejorar.

## Preguntas que resuelve el negocio

- ¿Qué clientes pueden abandonar el servicio?
- ¿Cuánto venderemos el próximo mes?
- ¿Qué transacciones parecen fraudulentas?
- ¿Qué producto recomendar a cada cliente?
- ¿Qué precio estimado tiene una propiedad?



## CASOS DE USO


## ¿Para qué usan ML las empresas?

| Área      | Uso de ML                | Valor generado         |
|-----------|--------------------------|------------------------|
| Ventas    | Predicción de demanda    | Mejor planificación    |
| Marketing | Segmentación de clientes | Campañas más efectivas |
| Banca     | Detección de fraude      | Menos pérdidas         |
| Retail    | Recomendaciones          | Más ventas             |
| Industria | Mantenimiento predictivo | Menos paradas          |
| Logística | Optimización de rutas    | Menores costes         |
| RR. HH.   | Análisis de rotación     | Mejor retención        |

**Clave** *Una empresa no compra modelos; compra mejores decisiones.*

## EL ORIGEN

# Cómo nace un proyecto de Machine Learning



## TRADUCCIÓN

## Del problema de negocio al problema de ML

| Problema de negocio          | Pregunta             | Tipo de problema ML       |
|------------------------------|----------------------|---------------------------|
| ¿El cliente se irá?          | Sí / No              | Clasificación             |
| ¿Cuánto venderemos?          | Número futuro        | Regresión                 |
| ¿Qué clientes son parecidos? | Grupos               | Clustering                |
| ¿Esta operación es extraña?  | Comportamiento raro  | Detección de anomalías    |
| ¿Qué producto recomendar?    | Preferencia probable | Sistemas de recomendación |

**Clave** *El equipo de datos traduce preguntas de negocio en problemas que un modelo puede aprender.*

## PROCESO

# El ciclo de vida de un proyecto ML



- 1 Definir la tarea
- 2 Recolectar y preparar datos
- 3 Explorar los datos
- 4 Entrenar modelos
- 5 Validar resultados
- 6 Desplegar el modelo
- 7 Monitorizar y mejorar

**Iterativo:** *el modelo se revisa cuando cambian los datos o el negocio.*

## EL EQUIPO

# Cómo trabaja un Data Scientist



- 1 Entender el problema con usuarios de negocio
- 2 Conseguir y limpiar los datos
- 3 Explorar patrones
- 4 Crear variables relevantes
- 5 Probar algoritmos
- 6 Evaluar métricas
- 7 Comunicar resultados
- 8 Llevar el modelo a producción con ingeniería
- 9 Evaluar los resultados del modelo en producción

# EL DÍA A DÍA EN UN PROYECTO DE MACHINE LEARNING

## LO QUE LA GENTE PIENSA



Entrenar modelos todo el día



Elegir el algoritmo "más inteligente"



Probar IA de última generación



Obtener el 99% de accuracy



Escribir mucho código de ML



El modelo queda listo y ya está

## LO QUE REALMENTE ES



Entender el problema de negocio



Buscar, limpiar y preparar datos



Experimentar con distintos modelos y parámetros



Comparar métricas y validar resultados



Trabajar con datos usando Pandas



Monitorear, desplegar y mejorar continuamente

## CICLO REAL DE UN PROYECTO DE MACHINE LEARNING



### 1. ENTENDER EL PROBLEMA

- Negocio
- Definir objetivo



### 2. CONSEGUIR LOS DATOS

- Fuentes
- Calidad



### 3. EXPLORAR LOS DATOS

- EDA



### 4. LIMPIAR Y PREPARAR

- Limpieza
- Transformaciones



### 5. FEATURE ENGINEERING

- Crear variables
- Seleccionar



### 6. ENTRENAR MODELOS

- Algoritmos
- Hiperparámetros



### 7. EVALUAR Y COMPARAR

- Métricas
- Validación



### 8. ELEGIR EL MEJOR

- Trade-offs
- Negocio



### 9. DESPLEGAR

- Producción
- Integración



### 10. MONITOREAR Y MEJORAR

- Performance
- Retraining



Entrenar un modelo suele ser una de las partes **más rápidas** de un proyecto de Machine Learning. Lo difícil es todo lo que ocurre **antes y después**.

## HERRAMIENTAS

# Entornos de trabajo en Machine Learning

## Aprendizaje y exploración

- Jupyter Notebook
- JupyterLab
- Google Colab
- Kaggle Notebooks

## Desarrollo profesional

- VS Code + Jupyter
- PyCharm
- GitHub

## Plataformas empresariales

- Azure Machine Learning
- Databricks

## Gestión de entornos

- Anaconda
- Conda
- Entornos virtuales de Python

**Clave** Cada entorno sirve para algo distinto: aprender, experimentar u operar modelos empresariales.

# Del notebook a producción

## Notebook

- Exploración
- Pruebas rápidas
- Métricas iniciales
- Código experimental



## Producción

- Integración con sistemas reales
- APIs · Seguridad
- Monitorización · Escalabilidad
- Retraining · Gobierno de datos

**Clave** *Que un modelo funcione en un notebook no significa que esté listo para una empresa.*



# Métricas técnicas vs métricas de negocio

## Métricas técnicas

- Accuracy
- Precision
- Recall
- F1 Score
- ROC AUC
- Error absoluto medio
- RMSE

vs

## Métricas de negocio

- Ahorro generado
- Ventas incrementadas
- Fraudes evitados
- Tiempo reducido
- Clientes retenidos
- Costes disminuidos
- Decisiones automatizadas

**Clave** *Un modelo puede tener buenas métricas técnicas y aun así no generar valor.*

## EL EQUIPO MULTIDISCIPLINARIO

# Roles involucrados

**Sponsor de negocio**

Define el objetivo

**Experto de negocio**

Aporta contexto

**Data Analyst**

Explora y entiende datos

**Data Scientist**

Entrena y evalúa modelos

**Data Engineer**

Prepara pipelines de datos

**ML Engineer**

Lleva modelos a producción

**DevOps / MLOps**

Automatiza y monitoriza


**Usuarios finales**

Usan las predicciones

**Un flujo común:** *del objetivo de negocio a las decisiones que usan los usuarios finales.*

## OPERACIÓN

# MLOps: mantener vivo el modelo



**Clave** *El modelo no termina al entrenarse: es útil cuando se mantiene funcionando en el mundo real.*

## CIERRE

# El Machine Learning no es el modelo

*El valor aparece cuando el modelo **mejora una decisión**, se **integra en un proceso** y es **usado por la organización**.*





IDEA PARA RECORDAR

“

**Una empresa no compra modelos.**

Compra decisiones **mejores**, más **rápidas** y más **rentables**.