

DATA ACADEMY · MACHINE LEARNING


Correlación, R^2 y Multicolinealidad

La pregunta que engancha: **¿podés confiar en el coeficiente de tu modelo?**

Qué mide y cómo se interpreta

- Mide la fuerza y el sentido de la relación lineal entre dos variables.
- **Rango acotado:** $r \in [-1, +1]$.
- Signo $\rightarrow$ dirección: + sube junto, - uno sube y otro baja.
- Magnitud $\rightarrow$ fuerza: $|r|$ cerca de 1 es lineal fuerte, cerca de 0 es débil.
- **Ojo: $r = 0$ sólo descarta relación lineal, no cualquier relación.**

$$r = \text{cov}(x, y) / (\sigma_x \cdot \sigma_y)$$



Misma dispersión, distinta relación lineal: el signo y la magnitud de r cuentan la historia.

03

CORRELACIÓN DE PEARSON

Ejemplo numérico paso a paso


Dataset chico — x = horas de estudio, y = nota (5 alumnos)

x	y	$x - \bar{x}$	$y - \bar{y}$	$dx \cdot dy$	dx^2	dy^2
1	1	-2	-2	4	4	4
2	3	-1	0	0	1	0
3	2	0	-1	0	0	1
4	4	1	1	1	1	1
5	5	2	2	4	4	4
$\bar{x}=3$	$\bar{y}=3$			$\Sigma=9$	$\Sigma=10$	$\Sigma=10$

$$r = \Sigma(dx \cdot dy) / \sqrt{(\Sigma dx^2 \cdot \Sigma dy^2)}$$

$$r = 9 / \sqrt{(10 \cdot 10)} = 9 / 10$$

$r = 0,90$ → correlación positiva fuerte



Los puntos siguen de cerca la recta → r alto.

R²: cuánta varianza explica el modelo

- R² = proporción de la varianza de y que el modelo logra explicar.
- Va de 0 (no explica nada) a 1 (ajuste perfecto).
- Compara el error del modelo contra el de predecir siempre la media $\bar{y}$.
- En regresión lineal simple se cumple: $R^2 = r^2$.

$$R^2 = 1 - \text{SS_res} / \text{SS_tot}$$

SS_res = $\sum (y_i - \hat{y}_i)^2$ · error del modelo

SS_tot = $\sum (y_i - \bar{y})^2$ · varianza total

SS_tot

Cuánto varía y por su cuenta, sin modelo.

SS_res

Cuánto queda sin explicar tras predecir.

Menos error residual

→ R² más alto → el modelo aporta sobre la media.

R² sobre el mismo dataset, paso a paso

Recta ajustada: $\hat{y} = 0,3 + 0,9 \cdot x$ ($b_1 = \Sigma dx \cdot dy / \Sigma dx^2 = 9/10$; $b_0 = \bar{y} - b_1 \bar{x}$)

x	y	$\hat{y} = 0,3 + 0,9x$	$y - \hat{y}$	$(y - \hat{y})^2$	$(y - \bar{y})^2$
1	1	1,2	-0,2	0,04	4
2	3	2,1	0,9	0,81	0
3	2	3,0	-1,0	1,00	1
4	4	3,9	0,1	0,01	1
5	5	4,8	0,2	0,04	4
			$\Sigma \rightarrow$	SS_res = 1,90	SS_tot = 10

$$R^2 = 1 - 1,90/10 = \mathbf{0,81} = r^2 = \mathbf{0,90^2}$$

Cómo leerlo

El modelo deja sin explicar sólo 1,90 de las 10 unidades de varianza total.

Explica el 81 % de la variación de las notas.

El residuo más grande (x=3) es el punto que más se aparta de la recta.

Por qué el R² común engaña

El R² común siempre sube

- Agregar cualquier variable nunca baja el R² — aunque sea ruido puro.
- El modelo siempre encuentra algún coeficiente que reduce un poco el error de entrenamiento.
- **Sumar variables correlacionadas infla la métrica sin agregar valor real.**
- Resultado: un R² alto puede ser sólo sobreajuste disfrazado.

El R² ajustado penaliza

$$R^2_{\text{adj}} = 1 - (1 - R^2) \cdot (n - 1) / (n - k - 1)$$

n = observaciones **k** = nº de predictores

- Cada variable nueva paga un costo por el término (n-k-1).
- **Si la variable no aporta suficiente, el R² ajustado baja.**
- Sirve para comparar modelos con distinta cantidad de predictores.

Qué es y cómo se lee

- Tabla cuadrada con la correlación de cada par de variables.
- **Diagonal = 1:** cada variable correlaciona perfecto consigo misma.
- Es simétrica: $\text{corr}(a,b) = \text{corr}(b,a)$, triángulos espejados.
- Se escanea buscando celdas con $|r|$ alto fuera de la diagonal.

Un $|r|$ alto entre dos predictoras es la primera señal de multicolinealidad.

Ejemplo teórico armado a mano (3×3)

	Precio	m ²	Amb.
Precio	1,00	0,92	0,85
m ²	0,92	1,00	0,88
Amb.	0,85	0,88	1,00

m² y **ambientes** comparten $r = 0,88 \rightarrow$ sospechá multicolinealidad.

En NumPy, Pandas y como heatmap

```
import numpy as np
import pandas as pd

# NumPy: cada fila es una variable
X = np.array([m2, ambientes, precio])
C = np.corrcoef(X)      # 3x3, diag = 1

# Pandas: más legible, con nombres
df = pd.DataFrame({
    "m2": m2, "amb": ambientes,
    "precio": precio})
df.corr()               # DataFrame

# Visualizar el patrón
df.corr().style.background_gradient()
sns.heatmap(df.corr(), annot=True)
```



Heatmap del dataset de departamentos: m^2 -ambientes = 0,83.

Definición y ejemplo central

Multicolinealidad: dos o más variables predictoras están muy correlacionadas entre sí, así que aportan información redundante al modelo.

Ejemplo: precios de departamentos

- m^2 y cantidad de ambientes crecen juntos: más ambientes casi siempre implica más superficie.
- En los datos, $\text{corr}(m^2, \text{ambientes}) \approx 0,83$.
- El modelo no puede separar cuánto del precio se debe a los m^2 y cuánto a los ambientes.
- Ambas contestan casi la misma pregunta: "¿qué tan grande es el depto?".

```
df[["m2", "amb"]].corr()  
#           m2      amb  
# m2      1.00  0.83  
# amb      0.83  1.00
```

Efectos entrelazados

El β de m^2 absorbe parte del efecto de ambientes (y viceversa): quedan indeterminados.

Cómo cuantificar la multicolinealidad

$$VIF_i = 1 / (1 - R^2_i)$$

- R^2_i = R^2 de regresar la variable i contra TODAS las demás predictoras.
- Si i se explica bien con las otras (R^2_i alto), su VIF se dispara.
- **Umbrales de referencia:** VIF > 5 sospecha, VIF > 10 grave.

```
from statsmodels.stats.outliers_influence \
    import variance_inflation_factor as vif
vif(X.values, i)  # VIF de la col. i
```

Aplicado al dataset de departamentos

Variable	R^2_i	$VIF = 1/(1-R^2_i)$	Estado
m ²	0,86	7,1	alerta
ambientes	0,84	6,3	alerta
antigüedad	0,05	1,1	ok

m²: $VIF = 1 / (1 - 0,86) = 1 / 0,14 = 7,1$

> 5 → m² y ambientes están inflando la varianza mutuamente.

Explicabilidad: el coeficiente se contamina

- Con variables entrelazadas, cada β deja de tener una lectura individual limpia.
- El efecto real se reparte entre m^2 y ambientes de forma arbitraria.
- No podés afirmar "cada m^2 extra suma X al precio" manteniendo lo demás fijo... porque no se mantiene fijo.
- Los signos y magnitudes dejan de ser confiables para argumentar.

Lo que querés decir

"Cada m^2 adicional aumenta el precio en \$1.500, con todo lo demás constante."


Lo que realmente pasa

Como m^2 y ambientes se mueven juntos, "mantener ambientes constante" mientras cambian los m^2 casi no ocurre en los datos.

El β de m^2 mezcla ambos efectos → la afirmación pierde sustento.

Inestabilidad: los β saltan bruscamente


- Pequeños cambios en los datos (agregar o quitar filas) mueven mucho los coeficientes.
- Los β pueden cambiar de magnitud e incluso de signo entre dos muestras casi iguales.
- El modelo no logra decidir a cuál variable atribuir el efecto compartido.
- Consecuencia: coeficientes poco reproducibles y difíciles de justificar.



Quitar 5 filas basta para que β de ambientes cambie de signo.


Errores estándar inflados

- La multicolinealidad agranda el error estándar de los coeficientes afectados.
- Intervalos de confianza más anchos → mayor incertidumbre sobre cada β .
- Los p-values pierden poder: variables realmente importantes pueden aparecer como "no significativas".
- Riesgo: descartar un predictor útil por leer mal su significancia.



Feature importance distorsionada en árboles

- En árboles y ensembles, dos variables correlacionadas se "turnan" en los splits.
- La importancia se reparte entre ellas: cada una aparece con menos peso del que tendría sola.
- Una variable clave puede parecer secundaria sólo por tener una gemela correlacionada.
- Cuidado al rankear variables por importancia sin revisar correlaciones.



No todos los modelos sufren igual

Familia de modelo	¿Afecta la predicción?	¿Afecta la interpretación?
Lineales (OLS, logística)	Sí — coeficientes inestables	Sí — β no interpretables
Basados en distancia (KNN, SVM)	Sí — pesa dos veces lo redundante	Parcial
Árboles / ensembles (RF, GBM)	Casi nula — predice igual	Sí — importancia repartida

Regla práctica: los lineales y los de distancia sufren en la predicción; los árboles la sostienen, pero todos pueden confundir la lectura de variables.

Misma multicolinealidad, distinto riesgo

1

Predicción pura

modelo robusto (RF, GBM)

Casi no afecta: el modelo predice bien igual.

RIESGO BAJO

2

Modelo lineal

OLS / regresión logística

Inestabilidad de coeficientes y errores estándar inflados.

RIESGO MEDIO

3

Interpretar el modelo

cualquier algoritmo

Siempre puede confundir la lectura de coeficientes o importancias.

RIESGO ALTO

Antes de preocuparte, preguntá: ¿mi objetivo es predecir o explicar?

Qué hacer al respecto

Eliminar la redundante

Quitar una de las variables casi gemelas (p. ej. dejar m^2 y sacar ambientes).

simple

Combinar o reducir dim.

Fusionarlas en un índice o aplicar PCA para condensar la información compartida.

PCA

Regularización

Ridge reparte el peso entre variables correlacionadas y estabiliza los coeficientes.

Ridge / L2

```
from sklearn.linear_model import Ridge
modelo = Ridge(alpha=1.0).fit(X, y)
```

```
# regularización L2 para modelos lineales
# coeficientes más estables ante colinealidad
```

No detectar multicolinealidad no significa "entrenar al pedo".

El modelo entrena y predice igual. El riesgo real está en cuánta confianza podés depositar en los coeficientes y en la importancia de variables que reportás.

- Predecir: casi siempre podés seguir tranquilo.
- Explicar: revisá correlaciones y VIF antes de sacar conclusiones.
- Ante la duda: eliminá, combiná o regularizá.