

GUÍA DOCENTE · SKLEARN.DATASETS

Datasets incluidos en Scikit-Learn

para aprender Machine Learning

Clasificación, regresión, features, labels y
modelos recomendados

6 toy datasets · scikit-learn 1.9



¿Qué es sklearn.datasets?

Permite cargar datasets listos para usar, sin descargar archivos externos en el caso de los toy datasets. Sirven para practicar carga de datos, análisis exploratorio, entrenamiento, evaluación y comparación de algoritmos.

data → X

Matriz de features

target → y

Variable objetivo

feature_names

Nombres de columnas predictoras

target_names

Nombres de las clases (si es clasificación)

DESCR

Descripción completa del dataset

as_frame=True

Carga como DataFrame de Pandas

Clasificación vs. regresión

Scikit-Learn documenta cuatro datasets de clasificación y dos de regresión entre los toy datasets.

4

CLASIFICACIÓN

Predecir una categoría

- Iris
- Wine
- Breast Cancer
- Digits

2

REGRESIÓN

Predecir un valor numérico

- Diabetes
- Linnerud — *regresión multisalida (3 targets)*

Dataset Iris

150

Muestras (50 × clase)

3

Clases

4

Features (cm)

Multiclase

Problema

Objetivo

Predecir la especie de una flor Iris a partir de medidas del sépalos y el pétalo.

Label

Setosa · Versicolour · Virginica

```
from sklearn.datasets
import load_iris
```

Uso didáctico El mejor dataset para explicar features vs. labels, visualización 2D y clasificación multiclase.

Iris: features y modelo de ejemplo

Feature	Descripción
sepal length	Largo del sépalo en cm
sepal width	Ancho del sépalo en cm
petal length	Largo del pétalo en cm
petal width	Ancho del pétalo en cm

Modelos recomendados

DecisionTreeClassifier
LogisticRegression
KNeighborsClassifier
SVC
RandomForestClassifier

```
dataset = load_iris()  
X = dataset.data      # features  
y = dataset.target    # labels
```

Idea clave X son las medidas de la flor; y es la especie. Mismo patrón para todos los datasets.

Dataset Wine

178

Muestras

13

Features químicas

3

Clases

Multiclase

Problema

13 atributos numéricos del análisis químico

alcohol · malic_acid · ash · alkalinity_of_ash ·
magnesium · total_phenols · flavanoids ·
nonflavanoid_phenols · proanthocyanins · color_intensity
· hue · od280/od315 · proline

Objetivo: clasificar vinos según el cultivador (class_0, class_1, class_2).

```
from sklearn.datasets  
import load_wine
```

Uso didáctico

Escalado de variables (magnitudes distintas)
Introducción a PCA y reducción de dimensión

Dataset Breast Cancer

569

Muestras

30

Features

2

Clases (212 M / 357 B)

Binaria

Problema

Grupo	Ejemplos
Medias	mean radius, mean texture...
Error estándar	radius error, area error...
Peores valores	worst radius, worst perimeter...

Features calculadas desde imágenes de una punción aspirativa (FNA); describen los núcleos celulares. Ideal para ver por qué la accuracy no alcanza sola.

```
from sklearn.datasets
import load_breast_cancer
```

Métricas clave

Accuracy · Precision · Recall · F1
Matriz de confusión · ROC AUC

Dataset Digits

1797

Muestras

64

Features (8×8 px)

10

Clases (0–9)

Multiclase

Problema

Elemento	Descripción
Imagen	Dígito manuscrito
Representación	Matriz 8×8 (valores 0–16)
Features	64 valores de píxeles
Label	Número real 0, 1, 2 ... 9

```
from sklearn.datasets
import load_digits
```

Uso didáctico

Una imagen también es una tabla de features
Puente entre ML clásico y visión por computadora

Dataset Diabetes

442

Pacientes

10

Features basales

25-346

Rango del target

Regresión

Problema

Feature	Descripción
age / sex	Edad · Sexo
bmi / bp	Índice de masa corporal · Presión
s1 / s2	Colesterol total · LDL
s3 / s4	HDL · Colesterol total / HDL
s5 / s6	Log triglicéridos · Azúcar en sangre

Target: medida cuantitativa de progresión de la diabetes un año después. Variables centradas y escaladas.

```
from sklearn.datasets
import load_diabetes
```

Modelos y métricas

LinearRegression · Ridge · Lasso
RandomForest / GradientBoosting
MAE · MSE · RMSE · R^2

Dataset Linnerud

20

Observaciones

3

Features (ejercicio)

3

Targets (fisiológicos)

Multisalida

Problema

Feature (X)	Descripción	Target (y)	Descripción
Chins	Dominadas	Weight	Peso
Situps	Abdominales	Waist	Cintura
Jumps	Saltos	Pulse	Pulso

```
from ...  
import load_  
linnerud
```

Uso didáctico Muestra que un modelo puede predecir varias salidas a la vez (Weight, Waist y Pulse), no solo una.

Tabla comparativa de datasets

Dataset	Tipo	Muestras	Features	Target
Iris	Clasif. multiclase	150	4	Especie de flor
Wine	Clasif. multiclase	178	13	Clase de vino
Breast Cancer	Clasif. binaria	569	30	Maligno / benigno
Digits	Clasif. multiclase	1797	64	Dígito 0–9
Diabetes	Regresión	442	10	Progresión de enfermedad
Linnerud	Regresión multisalida	20	3	Peso, cintura y pulso

Valores documentados en la sección de toy datasets de Scikit-Learn.

Features (X) vs. labels (y)

X son las columnas que el modelo usa para aprender.

y es la respuesta que queremos predecir.

Clasificación → y es una categoría.

Regresión → y es un número continuo.

```
dataset = load_iris()
X = dataset.data
y = dataset.target
```

Dataset	X (features)	y (label)
Iris	Medidas de la flor	Especie
Wine	Medidas químicas	Tipo de vino
Breast Cancer	Medidas celulares	Diagnóstico
Digits	Píxeles	Número
Diabetes	Variables clínicas	Progresión
Linnerud	Ejercicios	Var. fisiológicas

Modelos recomendados por tipo

Clasificación · Iris, Wine, Breast Cancer, Digits

`DecisionTreeClassifier`

`RandomForestClassifier`

`LogisticRegression`

`KNeighborsClassifier`

`SVC`

`GradientBoostingClassifier`

Regresión · Diabetes, Linnerud

`LinearRegression`

`Ridge`

`Lasso`

`DecisionTreeRegressor`

`RandomForestRegressor`

`GradientBoostingRegressor`

`MultiOutputRegressor`

Métricas por tipo de problema

Conecta los datasets con la evaluación, no solo con el entrenamiento.

Clasificación

Accuracy
Precision
Recall
F1-score
Matriz de confusión
ROC AUC (binaria)

Regresión

MAE — Error absoluto medio
MSE — Error cuadrático medio
RMSE — Raíz del MSE
 R^2 — Coeficiente de determinación

Ejemplo común de carga

```
from sklearn.datasets import load_iris

dataset = load_iris(as_frame=True)

X = dataset.data
y = dataset.target

print(X.head())
print(dataset.feature_names)
print(dataset.target_names)
```


Mensaje didáctico Todos estos datasets comparten la misma estructura: cambiar de dataset no cambia el flujo de trabajo.

Devuelve

data / target
feature_names
target_names
DESCR

Flujo de trabajo con un dataset

- 1 Cargar dataset
- 2 Explorar features y target
- 3 Dividir en train / test
- 4 Entrenar modelo
- 5 Predecir
- 6 Evaluar
- 7 Interpretar resultados



Limitaciones de estos datasets

Son pequeños

Pocas muestras por dataset

Están limpios

Sin trabajo previo de limpieza

Pocas columnas

Baja dimensionalidad

No son empresariales

No reflejan la complejidad real

Documentación Scikit-Learn aclara que son útiles para ilustrar algoritmos, pero suelen ser demasiado pequeños para tareas reales de ML.

EN RESUMEN

Ideales para aprender Machine Learning

Permiten concentrarse en el algoritmo, el flujo de trabajo y la evaluación, sin perder tiempo inicial en limpieza de datos.

● **Iris** → clasificación simple

● **Wine** → clasificación con más variables

● **Breast Cancer** → clasificación binaria

● **Digits** → imágenes como matriz de datos

● **Diabetes** → regresión

● **Linnerud** → regresión multisalida