


Métricas de regresión en Machine Learning

Cómo evaluar modelos predictivos de valores continuos

Ejemplo central: predicción del precio de casas (dataset de 100 propiedades).



¿Por qué necesitamos métricas?

Entrenar un modelo no alcanza: hay que medir cuánto se alejan sus predicciones de los valores reales — y con la métrica correcta.

- Un modelo puede parecer bueno y fallar justo en los casos importantes.
- Cada problema exige una métrica distinta.
- No todos los errores cuestan lo mismo.
- A veces importa el error promedio; a veces, los errores extremos.

Dónde importa medir bien el error

- Precio de viviendas
- Demanda de energía
- Predicción de ventas
- Riesgo crediticio
- Temperatura y clima
- Tiempos de entrega

Predicción vs. valor real

Todo se reduce a comparar el valor real con el valor predicho por el modelo.

VALOR REAL

Valor real

200 mil \$

El modelo predice

185 mil \$

RESIDUO

Valor real – predicho

residuo = +15 mil \$

200 mil \$ – 185 mil \$

+15 mil \$

El residuo: el bloque básico

El residuo es la diferencia entre el valor real y el predicho. Todas las métricas se construyen a partir de él.

- Residuo positivo: el modelo subestimó el valor real.
- Residuo negativo: el modelo sobreestimó el valor real.
- Cuanto más cerca de cero, mejor la predicción.
- Es la base de MAE, MSE, RMSE y R^2 .

$$e_i = y_i - \hat{y}_i$$

residuo = valor real – valor predicho

Subestima

real 200 · pred 185

$$e = +15$$

Sobreestima

real 150 · pred 160

$$e = -10$$

Caso base: 5 casas de ejemplo

5 casas · precios en miles de \$ · base de todos los cálculos

Casa	Precio real	Predicho	Residuo
1	200	185	+15
2	150	160	-10
3	300	280	+20
4	250	255	-5
5	180	160	+20

Lectura rápida

70 suma de |residuos|

1150 suma de residuos²

216 precio medio (mil \$)

5 casas de ejemplo

MAE



MAE

Promedia el valor absoluto de los errores: cuánto se equivoca el modelo en promedio, en las mismas unidades que la variable.

La pregunta que responde

¿Cuánto se equivoca el modelo en promedio?

FÓRMULA

$$\text{MAE} = \frac{\sum |y_i - \hat{y}_i|}{n}$$

Error medio, en las unidades originales

MAE en el caso base

Con las 5 casas de ejemplo

$$\text{MAE} = 70 / 5$$

$$= 14$$

El modelo se equivoca 14 mil \$ en promedio.

De dónde salen los números

	Valor
Suma de residuos	70
Número de casas (n)	5
Error máximo	20
Error mínimo	5

¿Cuándo conviene usar el MAE?

- Cuando quieres un error fácil de interpretar en dólares.
- Cuando todos los errores tienen un impacto similar.
- Cuando hay valores atípicos y no quieres que dominen.
- Cuando buscas una métrica robusta y estable.

Ejemplos donde funciona

- Precio de viviendas cuando importa el error medio real.
- Previsión de demanda con valores atípicos ocasionales.
- Reportes donde el error se explica en unidades claras.

En código (sklearn)

Calcular el MAE con las 5 casas, verificable a mano.

CÓDIGO (SKLEARN)

```
from sklearn.metrics import mean_absolute_error

y_real = [200, 150, 300, 250, 180]
y_pred = [185, 160, 280, 255, 160]


print(mean_absolute_error(y_real, y_pred))
```

SALIDA ESPERADA

14.0

(error medio = 14 mil \$)

MSE



MSE

Promedia el cuadrado de los errores. Al elevar al cuadrado, penaliza mucho más los errores grandes.

La pregunta que responde

¿Cuánto pesan los errores grandes?

FÓRMULA

$$\text{MSE} = \frac{\sum (y_i - \hat{y}_i)^2}{n}$$

Penaliza con fuerza los errores grandes

MSE en el caso base

Con las 5 casas de ejemplo

$$\text{MSE} = 1150 / 5$$

$$= 230$$

El error cuadrático medio es 230 (en miles de dólares²).

Elevamos cada residuo al cuadrado

$$\Sigma e^2 = 1150$$

suma de residuos²

$$n = 5$$

número de casas

En código (sklearn)

MSE y RMSE con las 5 casas de ejemplo.

CÓDIGO (SKLEARN)

```
from sklearn.metrics import mean_squared_error
import numpy as np
y_real = [200, 150, 300, 250, 180]
y_pred = [185, 160, 280, 255, 160]
mse = mean_squared_error(y_real, y_pred)
print("MSE:", mse)
print("RMSE:", np.sqrt(mse))
```


SALIDA ESPERADA

```
MSE: 230.0
RMSE: 15.166...
```

RMSE

Raíz del error cuadrático medio

Penaliza los errores grandes y se expresa en las mismas unidades que la variable objetivo (dólares).



La fórmula del RMSE

Es la raíz cuadrada del MSE. Vuelve a las unidades originales de la variable (dólares). Penaliza con fuerza los errores grandes. Muy usado para reportar el error de modelos de regresión.

La pregunta que responde

¿Cuánto se equivoca el modelo, en las unidades reales?

FÓRMULA

$$\text{RMSE} = \sqrt{\frac{\sum (y_i - \hat{y}_i)^2}{n}}$$

residuo = valor real – valor predicho

RMSE en el caso base

Partimos del MSE = 230 (5 casas).

$$\text{RMSE} = \sqrt{230}$$

$$\text{RMSE} \approx 15.17$$

En promedio, el modelo se desvía unos 15 mil dólares, penalizando más las casas peor estimadas.

Residuos de las 5 casas

$$\text{residuos} = [+15, -10, +20, -5, +20]$$

real – predicción (miles USD)

$$\text{residuo}^2 = [225, 100, 400, 25, 400]$$

$$\sum \text{residuo}^2 = 1150 \rightarrow \text{MSE} = 230$$

RMSE con scikit-learn

MSE y RMSE a partir de precios reales y predichos de viviendas.

CÓDIGO (SKLEARN)

```
from sklearn.metrics import mean_squared_error

import numpy as np
y_real = [200, 150, 300, 250, 180]

y_pred = [185, 160, 280, 255, 160]
mse = mean_squared_error(y_real, y_pred)
rmse = np.sqrt(mse)
print(f"MSE: {mse:.1f} RMSE: {rmse:.2f}")
```

SALIDA ESPERADA


```
MSE: 230.0
RMSE: 15.17
```

MAE vs RMSE

MAE

Trata todos los errores por igual. Más robusto frente a valores atípicos. Fácil de interpretar: error medio en dólares.


Caso base: $MAE = 14$ · $RMSE = 15.17$



RMSE

Penaliza con más fuerza los errores grandes. Muy sensible a los valores atípicos. Preferible cuando los grandes errores son costosos.

$RMSE \geq MAE$ siempre; a mayor diferencia, más dispersos los errores.



MAPE

La fórmula del MAPE

Mide el error relativo, en porcentaje. Independiente de la escala: fácil de comparar entre problemas. Se dispara cuando algún valor real es cercano a cero. Muy usado para comunicar resultados a negocio.

La pregunta que responde

¿Qué porcentaje de error cometemos, en promedio, respecto al valor real?

FÓRMULA

$$\text{MAPE} = \frac{100}{n}$$

$$\times \sum | (y_i - \hat{y}_i) / y_i |$$

Todas las métricas con scikit-learn


Un solo bloque calcula MAE, MSE, RMSE, MAPE y R^2 sobre los mismos datos.

CÓDIGO (SKLEARN)

```
from sklearn.metrics import mean_absolute_error, mean_squared_error,  
mean_absolute_percentage_error, r2_score  
  
import numpy as np                                # y_real vs y_pred (5 casas)  
y_real = [200, 150, 300, 250, 180]; y_pred = [185, 160, 280, 255, 160]  
  
mae = mean_absolute_error(y_real, y_pred); mse = mean_squared_error(y_real, y_pred)  
rmse = np.sqrt(mse); mape = mean_absolute_percentage_error(y_real, y_pred) * 100  
r2 = r2_score(y_real, y_pred); print(mae, mse, rmse, mape, r2)
```

SALIDA ESPERADA

```
MAE: 14.00    MSE: 230.00    RMSE: 15.17  
MAPE: 6.79%   R2: 0.919
```



R^2

La fórmula del R^2

Mide la proporción de varianza explicada por el modelo. 1 = predicción perfecta; 0 = no mejora la media. Puede ser negativo si el modelo es peor que la media. No tiene unidades: sirve para comparar modelos.

La pregunta que responde

¿Qué proporción de la varianza explica el modelo?

FÓRMULA

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$

$$SS_{res} = \sum (y_i - \hat{y}_i)^2 \quad \cdot \quad SS_{tot} = \sum (y_i - \bar{y})^2$$

R² en el caso base

$$SS_{\text{res}} = \sum \text{residuos}^2 = 1150$$

$$R^2 = 1 - 1150 / 14120$$

$$R^2 \approx 0.919$$

El modelo explica cerca del 92 % de la variabilidad de los precios.

Los componentes del caso base

SS_res	1150
--------	-------------

SS_tot (media = 216)	14120
----------------------	--------------

R ²	0.919
----------------	--------------


Cuándo R^2 engaña: el sobreajuste

30 variables en el modelo · el R^2 siempre sube · aunque no aporten

Un modelo sobreajustado a los datos

95%

de R^2 en train... y solo 62% en prueba.



Un R^2 alto no siempre significa un buen modelo.

R² vs R² ajustado

El R² ajustado penaliza las variables que no aportan; con muchas variables, guíate por él.

R²

Sube (o no baja) al añadir variables

Puede dar una impresión demasiado optimista. Útil para un modelo con un número fijo de variables.

R² AJUSTADO

$$R^2_{aj} = 1 - (1 - R^2) \cdot (n - 1) / (n - k - 1)$$

Penaliza añadir variables que no aportan. Solo sube si la nueva variable mejora de verdad el modelo. Preferible al comparar modelos con distinto número de variables.

CUÁNDO USAR CADA UNO

Con muchas variables, guíate por el R² ajustado: solo mejora cuando una nueva variable aporta información real al modelo.

Análisis de residuos

Graficar los residuos frente a los valores predichos revela problemas que una sola métrica esconde.

PATRÓN


Nube alrededor de cero

Nube sin patrón alrededor de cero: buen modelo. Forma de embudo: varianza no constante (heterocedasticidad).

SEÑALES

Curvas y atípicos

Curva o tendencia: falta una relación no lineal. Puntos muy alejados: posibles valores atípicos.



Q-Q Plot de los residuos

Compara la distribución de los residuos con una distribución normal teórica.

LECTURA


Puntos sobre la diagonal

Residuos aproximadamente normales; colas que se desvían indican valores extremos y una curvatura en S revela distribución sesgada.

IMPLICACIÓN

Normalidad de residuos

Respalda los intervalos de confianza. Ideal cuando planeas hacer inferencia estadística sobre el modelo.



Costo, tiempo y complejidad

Elige según el equilibrio entre precisión, tiempo de cómputo e interpretabilidad.

01

Regresión lineal / Ridge / Lasso:
entrenamiento muy rápido, fácil de interpretar.

02

Árboles de decisión: rápidos, pero propensos a sobreajustar.

03

Random Forest / Gradient Boosting:
más lentos y costosos, mayor precisión.

04

SVR: costoso en datasets grandes, sensible al escalado.

05

Modelos lineales: mejor equilibrio entre velocidad e interpretabilidad.

06

Ensembles: máxima precisión con mayor costo de cómputo.

Comparativa de modelos de regresión

Modelo	MAE	RMSE	R²	MAPE	R² aj.	Tiempo	Interpret.	Comentario práctico
Regresión lineal	18.2	22.5	0.86	9.1%	0.85	Muy bajo	Alta	Línea base rápida y explicable.
Ridge	17.9	22.0	0.87	8.9%	0.86	Muy bajo	Alta	Regulariza; reduce sobreajuste.
Lasso	18.0	22.3	0.86	9.0%	0.85	Muy bajo	Alta	Selecciona variables útiles.
Árbol de decisión	16.5	21.8	0.88	8.4%	0.87	Bajo	Media	Interpretable; propenso a sobreajuste.
Random Forest	12.1	15.4	0.93	6.2%	0.92	Medio	Media	Robusto y preciso; menos explicable.
Gradient Boosting	11.3	14.6	0.94	5.8%	0.93	Alto	Baja	Mejor R² con mayor coste.
SVR	15.8	20.1	0.90	8.0%	0.89	Alto	Baja	Fuerte en datasets pequeños.

Valores ilustrativos para el ejemplo de precios de vivienda.

¿Qué métrica usar?

Quieres un error fácil de explicar en dólares



MAE

Los errores grandes son especialmente costosos



RMSE / MSE

Necesitas comparar problemas de distinta escala



MAPE

Quieres saber cuánta varianza explica el modelo



R²

Comparas modelos con distinto número de variables



R² ajustado

Sospechas de sesgos o no linealidad



Análisis de residuos

Casi siempre conviene reportar más de una métrica.

Casos prácticos

CASO 1

Precio de viviendas

Métricas clave

MAE y RMSE en dólares para comunicar el error; R^2 para ver cuánta variabilidad se explica.

CASO 2

Demanda de energía

Métricas clave

RMSE para castigar los picos mal previstos; MAPE para comparar entre regiones de distinto tamaño.

CASO 3

Previsión de ventas

Métricas clave

MAPE para hablar en porcentajes con negocio; análisis de residuos para detectar estacionalidad no capturada.

CASO 4

Tiempos de entrega

Métricas clave

MAE para el error típico en minutos; RMSE si los grandes retrasos son críticos.

EN RESUMEN

La métrica correcta depende del costo real de cada tipo de error.

Errores comunes



Fijarse solo en R^2 e ignorar el error en unidades reales.



No mirar los residuos y perderse sesgos o no linealidad.



Usar MAPE cuando hay valores reales cercanos a cero.



Comparar modelos con métricas calculadas sobre conjuntos distintos.



Evaluar sobre los datos de entrenamiento en vez de un conjunto de prueba.



Reporta siempre la métrica junto con el conjunto de datos usado.



Olvidar escalar las variables antes de usar modelos sensibles (SVR).

Mensajes clave

01

El residuo es la base

todas las métricas parten de $y_i - \hat{y}_i$

02

MAE es intuitivo

error medio en las unidades reales, robusto a atípicos

03

RMSE castiga lo grande

penaliza con fuerza los errores más grandes

04

MAPE habla en %

ideal para comunicar, ojo con valores cerca de cero

05

R^2 mide lo explicado

proporción de varianza que captura el modelo

06

Nunca una sola métrica

combínalas y mira siempre los residuos

CIERRE

«Todos los modelos son erróneos, pero algunos son útiles.»

— *George E. P. Box*

